
مشروع عملي نظم استرجاع المعلومات 2026

بناء نظام استرجاع معلومات طبي

Information Retrieval System

ClinicalTrials 2017 / TREC Precision Medicine 2017

عدد الوثائق: 241,006

إعداد الفريق

الخضر الديواني

نايا سعدون

حلا العوض

ليث ضاهر

نوال صالح

التاريخ: 14 حزيران 2026

جدول المحتويات

1. الملخص التنفيذي
2. أهداف المشروع
3. توصيف Dataset
4. مراحل تنفيذ المشروع
5. المعالجة المسبقة ومعالجة الاستعلام
6. نماذج الاسترجاع
7. الفهرسة والتخزين
8. بنية النظام وفق SOA
9. واجهات التشغيل
10. الميزة الإضافية Grounded RAG
11. منهجية التقييم
12. التقييم الأساسي
13. Query Refinement
14. Sentence-BERT
15. تقييم RAG
16. لقطات النسخة التنفيذية
17. الاختبارات
18. تقسيم العمل
19. طريقة التشغيل
20. بنية المشروع GitHub
21. التحسينات المستقبلية
22. الخلاصة
23. المصادر

1. الملخص التنفيذي

لإعادة ترتيب نتائج BM25 وميزة Extractive Grounded RAG لإنتاج إجابة مستندة إلى الأدلة مع مصادر واضحة. الوثائق باستخدام TF-IDF و BM25 و LSA Embedding والتمثيل الهجين التسلسلي والمتوازي. يتضمن النظام Sentence-BERT التجارب السريرية الطبية. يقبل النظام استعلام المستخدم باللغة الطبيعية، ويطبق المعالجة المسبقة نفسها المستخدمة للوثائق، ثم يسترجع ويرتب يقدم هذا المشروع نظام استرجاع معلومات متخصصا في

ويقرأ النص حسب doc_id لحظة الاستعلام. أما الفهارس والنماذج فحفظت في artifacts جاهزة للتشغيل دون إعادة تدريب أثناء المقابلة. المشروع بلغة Python وفق SOA، مع واجهة Streamlit و REST API باستخدام FastAPI. تحفظ النصوص الأصلية في SQLite تم تنفيذ

2. أهداف المشروع

- بناء محرك بحث يعيد الوثائق الطبية الأكثر صلة باستعلام المستخدم.
- تنفيذ TF-IDF و BM25 و Embedding و Hybrid Serial و Hybrid Parallel.
- تطبيق معالجة مسبقة موحدة للوثائق والاستعلامات.
- توفير Query Refinement وتصحيح إملائي وتوسعة بالمرادفات.
- التحكم بمعاملات BM25 واختيار نموذج الاسترجاع من الواجهة.
- تقييم النماذج باستخدام qrels ومقاييس IR القياسية.
- إضافة RAG وتقييم جودة المصادر والـ grounding.
- تطبيق SOA وخدمات مستقلة و REST API قابلة للاختبار.

3. توصيف Dataset

تمثل لقطة من ClinicalTrials.gov لمسار TREC 2017 Precision Medicine، وتحتوي على وثائق واستعلامات و qrels رسمية. اعتمدت Dataset واحدة بناء على التوضيح النهائي للمعيدة، وهي clinicaltrials/2017/trec-pm-2017 من مكتبة ir_datasets.

الخاصية	القيمة
معرف Dataset	clinicaltrials/2017/trec-pm-2017
عدد الوثائق	241,006
عدد الاستعلامات	30
عدد qrels	13,019
اللغة	الإنجليزية
حقول الوثيقة	title, condition, summary, detailed_description, eligibility
حقول query	disease, gene, demographic, other

وقت البحث يرجع النظام doc_id ثم يقرأ النص غير المنظف من قاعدة البيانات، وهو شرط أساسي لضمان سرعة الاسترجاع وصحة العرض. تم دمج جميع حقول الوثيقة في حقل نمذجة واحد للفهرسة، بينما حفظ النص الأصلي الكامل في SQLite.

4. مراحل تنفيذ المشروع

المرحلة	الاسم	الوصف
1	تحميل البيانات	تحميل docs و queries و qrels باستخدام ir_datasets.
2	التخزين	دمج الحقول وحفظ النصوص الأصلية في SQLite على دفعات.
3	Preprocessing	الرموز stop words وإزالة tokenization و lowercase.
4	Indexing	بناء TF-IDF و BM25 sparse و LSA embeddings.
5	Query Processing	تطبيق المعالجة نفسها وتمثيل query حسب النموذج.
6	Retrieval	المطابقة والترتيب وإرجاع Top K.
7	BERT Reranking	إعادة ترتيب أفضل 50 مرشحا من BM25.
8	RAG	اختيار الجمل الأكثر ارتباطا وإضافة citations.
9	Evaluation	حساب المقاييس وتوليد CSV والرسوم.
10	Deployment	تشغيل Streamlit و FastAPI من artifacts الجاهزة.

5. المعالجة المسبقة ومعالجة الاستعلام

يتم تمرير النص المنظف مع `tokenizer=str.split` وتعطيل `tokenization` و `lowercase` الافتراضيين لمنع حدوث معالجة مزدوجة. الكلمات والأرقام وإزالة `stop words` والرموز والكلمات القصيرة. تستخدم الوظيفة نفسها للوثائق والاستعلامات. وعند بناء TF-IDF تنفذ `TextProcessor` تحويل النص إلى `lowercase` واستخراج

5.1 Query Refinement

الميزة اختيارية لأن التقييم أثبت أنها قد تحسن TF-IDF، لكنها قد تضيف كلمات عامة تقلل دقة BM25 في الاستعلامات الجينية والطبية الدقيقة. Query Refinement Service بتصحيح أخطاء شائعة مثل `diabetis` إلى `diabetes`، ثم تضيف عددا محدودا من المرادفات. أبقى

تقوم

6. نماذج تمثيل واسترجاع الوثائق

آلية العمل	النوع	الطريقة
حساب cosine similarity بين query والوثائق.	VSM	TF-IDF
نموذج sparse مع k1 و b قابلين للتغيير.	Probabilistic	BM25
ضغط TF-IDF إلى 64 بعدا دلاليا.	TruncatedSVD	LSA Embedding
دمج درجات TF-IDF و BM25 و LSA.	Fusion	Hybrid Parallel
يعيد ترتيبهم LSA يجلب المرشحين ثم BM25	Reranking	Hybrid Serial
إعادة ترتيب أفضل 50 مرشحا من BM25.	Semantic Reranking	Sentence-BERT

فيجمع درجة BM25 مع درجة LSA للمرشحين. Sentence-BERT يستخدم نموذج all-MiniLM-L6-v2 محليا ولا يعيد بناء الفهرس. يستخدم Hybrid Parallel أوزانا افتراضية 0.25 لـ TF-IDF و 0.60 لـ BM25 والباقي لـ LSA. أما Hybrid Serial

7. الفهرسة والتخزين


في `search_index.joblib` بحجم يقارب 382MB، وحفظت 241,006 وثيقة أصلية في `documents.sqlite` بحجم يقارب 1.1GB. feature و `min_df=2` و `max_df=0.95` وبنوع `float32`. استخدم BM25 مصفوفة sparse بنفس `vocabulary`. حفظ الفهرس

بني TF-IDF بحد أقصى 30,000

- documents.sqlite: doc_id النصوص الأصلية مع فهرس على.
- search_index.joblib: TF-IDF و SVD و embedding matrix و BM25.
- dataset_metadata.json: تعريف Dataset ومعاملات البناء.
- evaluation_metrics*.csv: تقارير التقييم المختلفة.

8. بنية النظام وفق SOA

Streamlit و FastAPI الحاوية نفسها، وبذلك تبقى الواجهات منفصلة عن تفاصيل الفهرسة والتخزين وتزداد قابلية الصيانة وإعادة الاستخدام. واضحة. ServiceContainer يحمل الفهرس وقاعدة البيانات مرة واحدة ويحققها في RetrievalService و RagService. تستخدم قسم النظام إلى خدمات مستقلة ذات مسؤوليات



الشكل 1: System Architecture وفق SOA

الخدمة	الملف	المسؤولية
Data Service	data_service.py	تحميل Dataset و qrels ودمج الحقول.
Document Store	database.py	حفظ واسترجاع النص الأصلي من SQLite.
Preprocessing	text_processing.py	تنظيف النصوص والاستعلامات.
Query Refinement	query_refinement.py	التصحيح الإملائي والمرادفات.
Indexing	indexing_service.py	بناء TF-IDF و BM25 و LSA.
Retrieval	retrieval_service.py	البحث والترتيب والهجين و BERT.
Evaluation	evaluation_service.py	حساب مقاييس IR.
RAG	rag_service.py	إجابة مؤرصة ومصادر وأدلة.
API Gateway	api.py	واجهات health/search/rag/metrics.
UI	app.py	واجهة Streamlit.

9. واجهات التشغيل

9.1 Streamlit UI

و Top K ومعاملات BM25 k1 و b، وتشغيل Query Refinement، والتنقل بين Search و RAG Chat و Evaluation. تتيج اختيار Retrieval method

9.2 FastAPI Gateway

Endpoint	الوظيفة
GET /health	فحص الجاهزية وعدد الوثائق.
POST /search	تنفيذ البحث مع النموذج والمعاملات.
POST /rag	إرجاع الإجابة والأدلة والمصادر.
GET /metrics	إرجاع تقارير التقييم بصيغة JSON.

توثيق OpenAPI التفاعلي متاح على <http://127.0.0.1:8000/docs>.

10. الميزة الإضافية: Grounded RAG

أدلة مرقمة، ثم تعرض المصادر مع doc_id و score. هذا التصميم Extractive RAG، لذلك لا يولد ادعاءات خارج الوثائق الأصلية. تسترجع RAG Service أفضل الوثائق، ثم تقسم النص إلى جمل وتختار الجملة ذات أكبر تقاطع مع كلمات السؤال. تعرض أفضل ثلاثة

11. منهجية التقييم


وثيقة لكل query لحساب MAP@1000 و Recall@1000، بينما حسب nDCG@10 و Precision@10 على أول عشر نتائج. استخدمت qrels الرسمية لـ 29 استعلاما. استرجع النظام أفضل 1000

- عبر الاستعلامات حتى عمق 1000 Average Precision متوسط: MAP@1000.
- جودة ترتيب أول عشر نتائج مع درجات الملاءمة: nDCG@10.
- نسبة الوثائق الملائمة ضمن أول عشر نتائج: Precision@10.
- نسبة الوثائق الملائمة المسترجعة حتى عمق 1000: Recall@1000.

12. نتائج التقييم الأساسية

Method	MAP@1000	nDCG@10	P@10	Recall@1000
tfidf	0.0912	0.1259	0.1621	0.5902
bm25	0.1921	0.2892	0.3000	0.6787
embedding	0.0013	0.0045	0.0138	0.0763
hybrid_parallel	0.1476	0.2292	0.2345	0.6086
hybrid_serial	0.1770	0.2948	0.2862	0.6468

الترتيب التسلسلية على رفع الوثائق شديدة الملاءمة إلى المراتب الأولى. كانت LSA ضعيفة بسبب ضغط المصطلحات الطبية إلى 64 بعدا. حقق Hybrid Serial أفضل nDCG@10. يرجع ذلك إلى قدرة BM25 على التعامل مع تكرار المصطلحات وطول الوثيقة، وقدرة إعادة حقق BM25 أفضل MAP و Precision و Recall، بينما



الشكل 2: مقارنة نماذج الاسترجاع الأساسية

13. تقييم Query Refinement

Method	MAP@1000	nDCG@10	P@10	Recall@1000
tfidf	0.0910	0.1350	0.1724	0.5794
bm25	0.1766	0.2742	0.3034	0.6494
embedding	0.0019	0.0037	0.0103	0.1237
hybrid_parallel	0.1430	0.2324	0.2310	0.6007
hybrid_serial	0.1640	0.2786	0.2793	0.6390

السبب هو أن المراتفات العامة قد تزيد الضجيج في استعلامات الأمراض والجينات، لذلك بقي الخيار قابلاً للتفعيل والإيقاف من الواجهة. حسنت الميزة بعض نتائج TF-IDF و Recall الخاص بـ LSA، لكنها خفضت MAP و Recall في BM25 والهجين.

14. تقييم Sentence-BERT

Method	MAP@10	nDCG@10	P@10	Recall@10
bert_rerank	0.0556	0.2474	0.2655	0.0864

وتفوق دلاليًا على LSA. استخدم كمرحلة reranking فوق أفضل 50 نتيجة من BM25 لتقليل زمن التنفيذ وحجم التخزين. حقق $P@10=0.2655$ و $BERT\ nDCG@10=0.2474$.

15. تقييم RAG قبل وبعد الميزة الإضافية

Source P@5	Source Recall@5	Query Coverage	Citation Coverage	Groundedness
0.2483	0.0604	0.4352	0.6000	1.0000

يثبت أن كل جملة دليل موجودة في الوثائق الأصلية. $Citation\ Coverage=0.6$ لأن الإجابة تستخدم أفضل ثلاثة أدلة من خمسة مصادر. قبل RAG يعرض النظام الوثائق فقط، وبعدها يعرض إجابة وأدلة ومصادر. $Groundedness=1.0$.

16. لقطات النسخة التنفيذية

The screenshot displays the 'Information Retrieval System' web application. On the left, a 'Configuration' sidebar shows settings for the dataset ('clinicaltrials/2017/trec-ppm-2017'), the number of documents (241006), the retrieval method ('hybrid_parallel'), and sliders for 'Top K' (set to 10), 'BM25 k1' (set to 1.50), and 'BM25 b' (set to 0.75). A 'Query refinement' checkbox is checked. The main panel, titled 'Information Retrieval System', has tabs for 'Search', 'RAG Chat', and 'Evaluation'. The 'Search' tab is active, showing a search query 'lung cancer EGFR adult' and a 'Search' button. Below the button, the results are displayed, starting with a numbered list item '1. NCT01360931' and a 'Hybrid-Parallel score: 0.8869'. The main content area shows a title 'Title: The Roles of Neutrophil Elastase in Lung Cancer Summary' followed by a detailed text summary of lung cancer statistics and treatment options. The bottom of the image shows a Windows taskbar with various application icons and a system clock indicating 9:45 PM on 6/14/2026.

الشكل 3: البحث الهجين وعرض الوثائق الأصلية

The screenshot displays the 'Information Retrieval System' web application. The interface is divided into a left sidebar for configuration and a main content area for search and results.


Configuration Panel (Left Sidebar):

- Dataset:** clinicaltrials/2017/trec-ps-2017
- Documents:** 241006
- Retrieval method:** hybrid_parallel
- Top K:** 10
- BM25 k1:** 1.50
- BM25 b:** 0.75
- ☐ Query refinement


Main Content Area:

- Search:** RAG Chat Evaluation
- Ask a question:** Which clinical trials discuss lung cancer and EGFR?
- Generate grounded answer:** (button)
- Grounded answer based on the retrieved clinical-trial documents:**
 - [1] Detailed Description: Background: - There is a growing body of evidence that points to genetic heterogeneity of the EGFR pathway in non-small cell lung cancer among different ethnic groups and that underscores the need for consideration of these differences in patient management and in the design of future trials of agents that target the EGFR pathway.
 - [2] We have also tested the NE activity of a lung adenocarcinoma cell line A549 and found that radio-labelled cells migrate into lung cancer cells and is enzymatically inactive (unpublished data) Lung cancer cell lines and normal bronchial epithelial cells and clinical lung cancer tissue bank We have recently established primary lung cancer and normal bronchial epithelial cell lines from local Chinese patients and they were characterized with in vitro growth kinetics, morphological and immunohistochemical studies and gene expression profiling [16].


الشكل 4: Grounded RAG مع citations



الشكل 5: التقييم الأساسي وتقييم Query Refinement



الشكل 6: تقييم Sentence-BERT و RAG



الشكل 7: الرسم البياني النهائي

17. الاختبارات وضمان الجودة

RAG. نجحت الاختبارات الأربعة، كما نجح compile واختبار REST API والبحث باستخدام BM25 و BERT على الفهرس الكامل. أضيفت اختبارات مستقلة باستخدام unittest لخدمة SQLite والمعالجة المسبقة وتحسين الاستعلام ومقاييس التقييم و grounding أمر الاختبار: run_tests.cmd\.

18. تقسيم العمل بين أعضاء الفريق

المهام	العضو
تجهيز Dataset، إدارة qrels، التدريب على Colab، وتكامل الملفات النهائية.	الخضر الديواني
المعالجة المسبقة، معالجة الاستعلام، وتحسين الاستعلام.	نايا سعدون
وتمثيل الوثائق والاستعلامات، TF-IDF، LSA Embedding.	حلا العوض
الاسترجاع الهجين التسلسلي والمتوازي، والترتيب، BM25.	ليث ضاهر
التقييم، واجهة RAG، Streamlit، وتجهيز التقرير.	نوال صالح

19. النسخة التنفيذية وطريقة التشغيل

جاهزة للمقابلة دون إعادة التدريب. يجب الاحتفاظ بمجلد artifacts على جهاز العرض لأن الفهرس وقاعدة البيانات أكبر من حدود GitHub. النسخة التنفيذية

الأمور / الرابط	المكون
http://localhost:8501 ثم run_app.cmd\.	واجهة Streamlit
http://127.0.0.1:8000/docs ثم run_api.cmd\.	REST API

المكون	الرابط / الأمر
الاختبارات	.run_tests.cmd
CLI	python scripts\search.py "lung cancer EGFR adult" --method bm25 --top-k 10

عبر واجهتين تنفيذيتين: Streamlit للمستخدم وFastAPI للتكامل. ومن كل واجهة يمكن الاستعلام باستخدام النماذج الأساسية والهجينة. يوفر المشروع محرك البحث

20. بنية المشروع GitHub

رابط GitHub: https://github.com/khaderaldiwani/ir_project

المسار	المحتوى
src/ir_project/services	الخدمات المستقلة.
scripts	التحضير والبحث والتقييم.
notebooks	نوت بوك Colab للتدريب.
artifacts	Git، الملفات الضخمة مستثناة من CSV و metadata
reports	التقرير والصور والرسوم.
app.py	واجهة Streamlit.
api.py	FastAPI Gateway.
README.md	شرح البنية والتشغيل.

21. القيود والتحسينات المستقبلية

- استخدام Biomedical Sentence-BERT متخصص بالمجال الطبي.
- إضافة Learning to Rank لتعلم أوزان الدمج.
- إضافة مولد لغوي محلي مع الحفاظ على evidence و citations.
- نقل قاعدة البيانات إلى PostgreSQL أو MongoDB عند التشغيل الموزع.
- إضافة cache للاستعلامات وقياس زمن الاستجابة.

22. الخلاصة

النتائج تفوق BM25 و Hybrid Serial، وفائدة BERT ك-reranker، وحقق RAG groundedness كاملا مع مصادر واضحة. الاستعلام والتقييم. كما يطبق SOA عمليا عبر خدمات مستقلة و ServiceContainer و FastAPI، ويقدم نسخة تنفيذية مستقرة. أظهرت ألف وثيقة. يحقق النظام المعالجة والفهرسة وتمثيلات TF-IDF و BM25 و Embedding والتمثيل الهجين والاسترجاع والترتيب وتحسين تم بناء نظام استرجاع معلومات متكامل على Dataset كاملة تتجاوز 200

23. المصادر والمراجع

1. IR Datasets Clinical Trials: <https://ir-datasets.com/clinicaltrials.html>
2. Roberts, K. et al. Overview of the TREC 2017 Precision Medicine Track, TREC 2017.
3. TREC Precision Medicine: <https://trec.nist.gov/data/precmed.html>

4. Robertson, S. and Zaragoza, H. BM25 and Beyond, 2009. <https://doi.org/10.1561/15000000019>
5. scikit-learn TfidfVectorizer:
https://scikit-learn.org/stable/modules/generated/sklearn.feature_extraction.text.TfidfVectorizer.html
6. scikit-learn TruncatedSVD:
<https://scikit-learn.org/stable/modules/generated/sklearn.decomposition.TruncatedSVD.html>
7. Reimers, N. and Gurevych, I. Sentence-BERT, 2019: <https://arxiv.org/abs/1908.10084>
8. Sentence Transformers: <https://www.sbert.net/>
9. FastAPI: <https://fastapi.tiangolo.com/>
10. Streamlit: <https://docs.streamlit.io/>
11. SQLite: <https://www.sqlite.org/docs.html>